EDA - Exploratory Data Analysis datos energéticos España.

Hourly energy demand generation and weather

Electrical demand, generation by type, prices and weather in Spain

Pilar Denia García

The Bridge _ 01/Dic/2020

Contenido

0.- INTRODUCCIÓN

Este es un ejercicio absolutamente educativo, para afianzar los conocimientos y contenidos que se están adquiriendo en el bootcamp impartido en TheBridge, edición Junio2020 modalidad Part_Time.

La finalidad del EDA es descubrir los patrones en los datos. Esto es fundamental para dirigirlos hacia un modelado predictivo con un objetivo final de anticipación a la hora de toma de decisiones por parte del área de negocio.

Los pasos a seguir son:

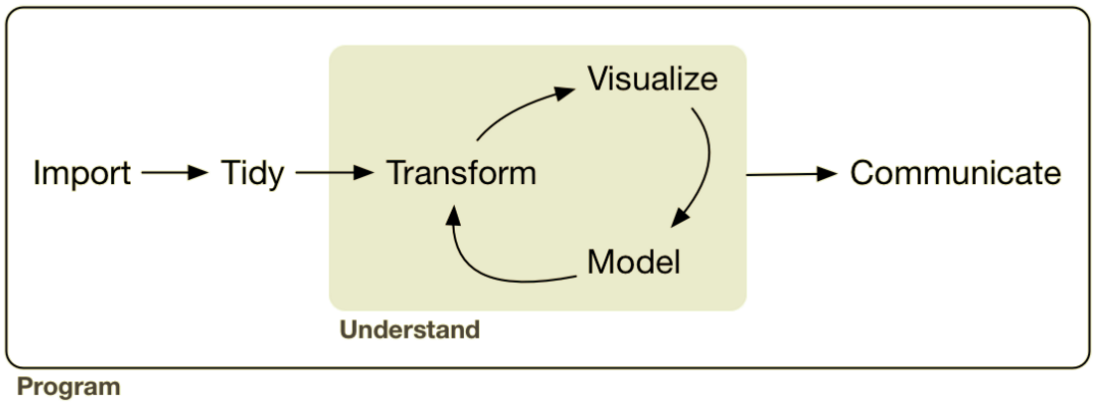

Img_01 . – Fases del Exploratory Data Analysis.

Proceso del ejercicio exploratorio:

- Selección de las fuentes
- Importación de el/los conjunto/s de dato/s
- Estudio y ordenación
- Transformación de los datos
- Visualización de variables

1.- OBJETIVO

La energía es uno de los recursos en la vida de los seres humanos junto con otras necesidades esenciales que se ha vuelto primordial.

El hombre moderno se vale de la energía eléctrica para facilitar la realización de multitud de actividades complejas, y que ha supuesto una evolución y desarrollo exponencial desde principios del S.XIX.

Como ya se sabe el principio de la energía es que ni se crea ni se destruye sólo se transforma, la cantidad de energía se mantiene constante. Ahí radica la dificultad de mantener el equilibrio entre la demanda y la generación, puesto que el exceso se perdería y, en caso contrario podría provocar una caída de la red, con un impacto económico y social más importante.

Una de las finalidades del estudio objeto de este ejercicio es poder predecir la demanda para mantener ese equilibro energético.

El segundo y no menos importante para el negocio es predecir el precio a aplicar teniendo en cuenta cual será la fuente de origen que genere dicha energía.

España es un país con una fuerte dependencia de los recursos fósiles, y sin ser productores de esta materia prima, el impacto en precio energético (kWh) es alto. Por otra parte, si esa generación se obtiene de las fuentes renovables el coste y, por tanto, el precio/hora disminuye.

La generación renovable tanto la eólica como la solar, están directamente vinculadas a los efectos atmosféricos; sol, nubes, lluvia, viento, temperatura. De ahí que se haga uso también de información climatológica en el ejercicio exploratorio.

2.- DATOS

En el ejercicio se analiza la información obtenida en la plataforma kaggel sobre un conjunto de datos que abarcan 4 años (Enero2015 a Diciembre2018) en España en intervalos de 1h:

A.- Documento en formato '.csv' con un peso de 28,8MB. A través de dos fuentes de origen con datos abiertos; Entsole Transparency Platform facilita los registros sobre la generación energética, previsión y demanda ,y el precio se recoge desde Red Electric España.

Fichero 'energy_dataset.csv' está distribuido en:

Field	Values
time	Datetime index localized to CET
generation biomass	biomass generation in MW
generation fossil brown coal/lignite	coal/lignite generation in MW
generation fossil coal-derived gas	coal gas generation in MW
generation fossil gas	gas generation in MW
generation fossil hard coal	coal generation in MW
generation fossil oil	oil generation in MW
generation fossil oil shale	shale oil generation in MW
generation fossil peat	peat generation in MW
generation geothermal	geothermal generation in MW
generation hydro pumped storage aggregated	hydro1 generation in MW
generation hydro pumped storage consumption	hydro2 generation in MW
generation hydro run-of-river and poundage	hydro3 generation in MW
generation hydro water reservoir	hydro4 generation in MW
generation marine	sea generation in MW
generation nuclear	nuclear generation in MW
generation other	other generation in MW
generation other renewable	other renewable generation in MW
generation solar	solar generation in MW

generation waste	waste generation in MW
generation wind offshore	wind offshore generation in MW
generation wind onshore	wind onshore generation in MW
forecast solar day ahead	forecasted solar generation
forecast wind offshore eday ahead	forecasted offshore wind generation
forecast wind onshore day ahead	forecasted onshore wind generation
total load forecast	forecasted electrical demand
total load actual	actual electrical demand
price day ahead	forecasted price EUR/MWh
price actual	price in EUR/MWh

B.- Archivo también en formato '.csv' (18,9 MB), recoge información climatológica de las 5 ciudades más importantes del país. Los parámetros del clima definidos en el dataset se pueden consultar en documentación informativa de la API.

Fichero 'weather_features.csv' está distribuido en las columnas:

Field	Values
time	Datetime index localized to CET
city_name	name of city
temp	in k
temp_min	minimum in k
temp_max	maximum in k
pressure	pressure in hPa
humidity	humidity in %
wind_speed	wind speed in m/s
wind_deg	wind direction
rain_1h	rain in last hour in mm
rain_3h	rain last 3 hours in mm
snow_3h	show last 3 hours in mm
clouds_all	cloud cover in %
weather_id	Code used to describe weather
weather_main	Short description of current weather
weather_description	Long description of current weather
weather_icon	Weather icon code for website

3.- EXPLORATORIO

GENERAL

Se empieza importando los módulos necesarios. Se harán uso de :

- Numpy
- Pandas
- Datetime
- Calendar
- OS

Visualización:

- Matplotlib.pyplot
- Seaborn
- Plotly.offline.iplot
- Plotly.graph_objs

Módulo propio con funciones de tratamiento personalizado

- Functions_EDA

ENERGY:

1.b) DESCARGA DE FICHERO

Se importa fichero '.csv' de datos energéticos.
Se comprueba que todos los registros facilitados en la plataforma sean descargado correctamente.
La dimensión inicial del dataset es de 35064 registros y 29 columnas.
La filas recoge los atributos:

```
energy.info()
```

```
RangeIndex: 35064 entries, 0 to 35063
Data columns (total 29 columns):
 #   Column                                       Non-Null Count  Dtype
---  ------                                       --------------  -----
 0   time                                         35064 non-null  object
 1   generation biomass                           35045 non-null  float64
 2   generation fossil brown coal/lignite         35046 non-null  float64
 3   generation fossil coal-derived gas           35046 non-null  float64
 4   generation fossil gas                        35046 non-null  float64
 5   generation fossil hard coal                  35046 non-null  float64
 6   generation fossil oil                        35045 non-null  float64
 7   generation fossil oil shale                  35046 non-null  float64
 8   generation fossil peat                       35046 non-null  float64
 9   generation geothermal                        35046 non-null  float64
 10  generation hydro pumped storage aggregated   0 non-null      float64
 11  generation hydro pumped storage consumption  35045 non-null  float64
 12  generation hydro run-of-river and poundage   35045 non-null  float64
 13  generation hydro water reservoir             35046 non-null  float64
 14  generation marine                            35045 non-null  float64
 15  generation nuclear                           35047 non-null  float64
 16  generation other                             35046 non-null  float64
 17  generation other renewable                   35046 non-null  float64
 18  generation solar                             35046 non-null  float64
 19  generation waste                             35045 non-null  float64
 20  generation wind offshore                     35046 non-null  float64
 21  generation wind onshore                      35046 non-null  float64
 22  forecast solar day ahead                     35064 non-null  float64
 23  forecast wind offshore eday ahead            0 non-null      float64
 24  forecast wind onshore day ahead              35064 non-null  float64
 25  total load forecast                          35064 non-null  float64
 26  total load actual                            35028 non-null  float64
 27  price day ahead                              35064 non-null  float64
 28  price actual                                 35064 non-null  float64
dtypes: float64(28), object(1)
memory usage: 7.8+ MB
```

Puesto que el objetivo es determinar el precio, se establece como 'target' la columna 'price actual'.

Precio ➔ dato numérico ➔ regresión.

2.b) INDICE ENERGY

Se asigna como índice la columna temporal conservando 'utc'.

3.b) NAN VALUES

Inicialmente, se revisa la naturaleza de los datos de las columnas, la cantidad de Nan/null o datos a '0'.

```
#check how many total rows and columns we have and how many of those are missing or zero values.
print(('NUMBER NULL/NAN_VALUES OF COLUMNS DATAFRAME:\n'))
energy.isnull().sum()
```

```
NUMBER NULL/NAN_VALUES OF COLUMNS DATAFRAME:

[34]:
generation biomass                            19
generation fossil brown coal/lignite          18
generation fossil coal-derived gas            18
generation fossil gas                         18
generation fossil hard coal                   18
generation fossil oil                         19
generation fossil oil shale                   18
generation fossil peat                        18
generation geothermal                         18
generation hydro pumped storage aggregated    35064
generation hydro pumped storage consumption   19
generation hydro run-of-river and poundage    19
generation hydro water reservoir              18
generation marine                             19
generation nuclear                            17
generation other                              18
generation other renewable                    18
generation solar                              18
generation waste                              19
generation wind offshore                      18
generation wind onshore                       18
forecast solar day ahead                      0
forecast wind offshore eday ahead             35064
forecast wind onshore day ahead               0
total load forecast                           0
total load actual                             36
price day ahead                               0
price actual                                  0
dtype: int64
```

4.b) SIMPLIFICACIÓN ATRIBUTOS

Se simplifica el DataFrame a las fuentes principales de generación. Se agrupa la generación eléctrica por; fósil, hidráulica, nuclear, solar, eólica y en otras (renovables y no renovables).

Una vez se han agrupado las columnas indicadas, se vuelve a verificar las que tienen datos tipo 'NaN', y cuantos registros en cada serie.

```
energy.isnull().any()
```

```
generation fossil          False
generation hydro           False
generation nuclear          True
generation other           False
generation solar            True
generation wind            False
forecast solar day ahead    False
forecast wind eday ahead    False
total load forecast        False
total load actual           True
price day ahead            False
price actual               False
dtype: bool
```

```
NUMBER NULL/NAN_VALUES OF COLUMNS DATAFRAME:

                                                                    [47]:
generation fossil          0
generation hydro           0
generation nuclear        17
generation other           0
generation solar          18
generation wind            0
forecast solar day ahead     0
forecast wind eday ahead     0
total load forecast        0
total load actual         36
price day ahead            0
price actual               0
dtype: int64
```

5.b) HISTOGRAMAS.

Con la visualización gráfica de los histogramas de las variables del dataset 'energy', se inicia el estudio de las funciones de densidad de probabilidad del conjunto de datos, así como intuir la naturaleza de las muestras en cada uno de los atributos.

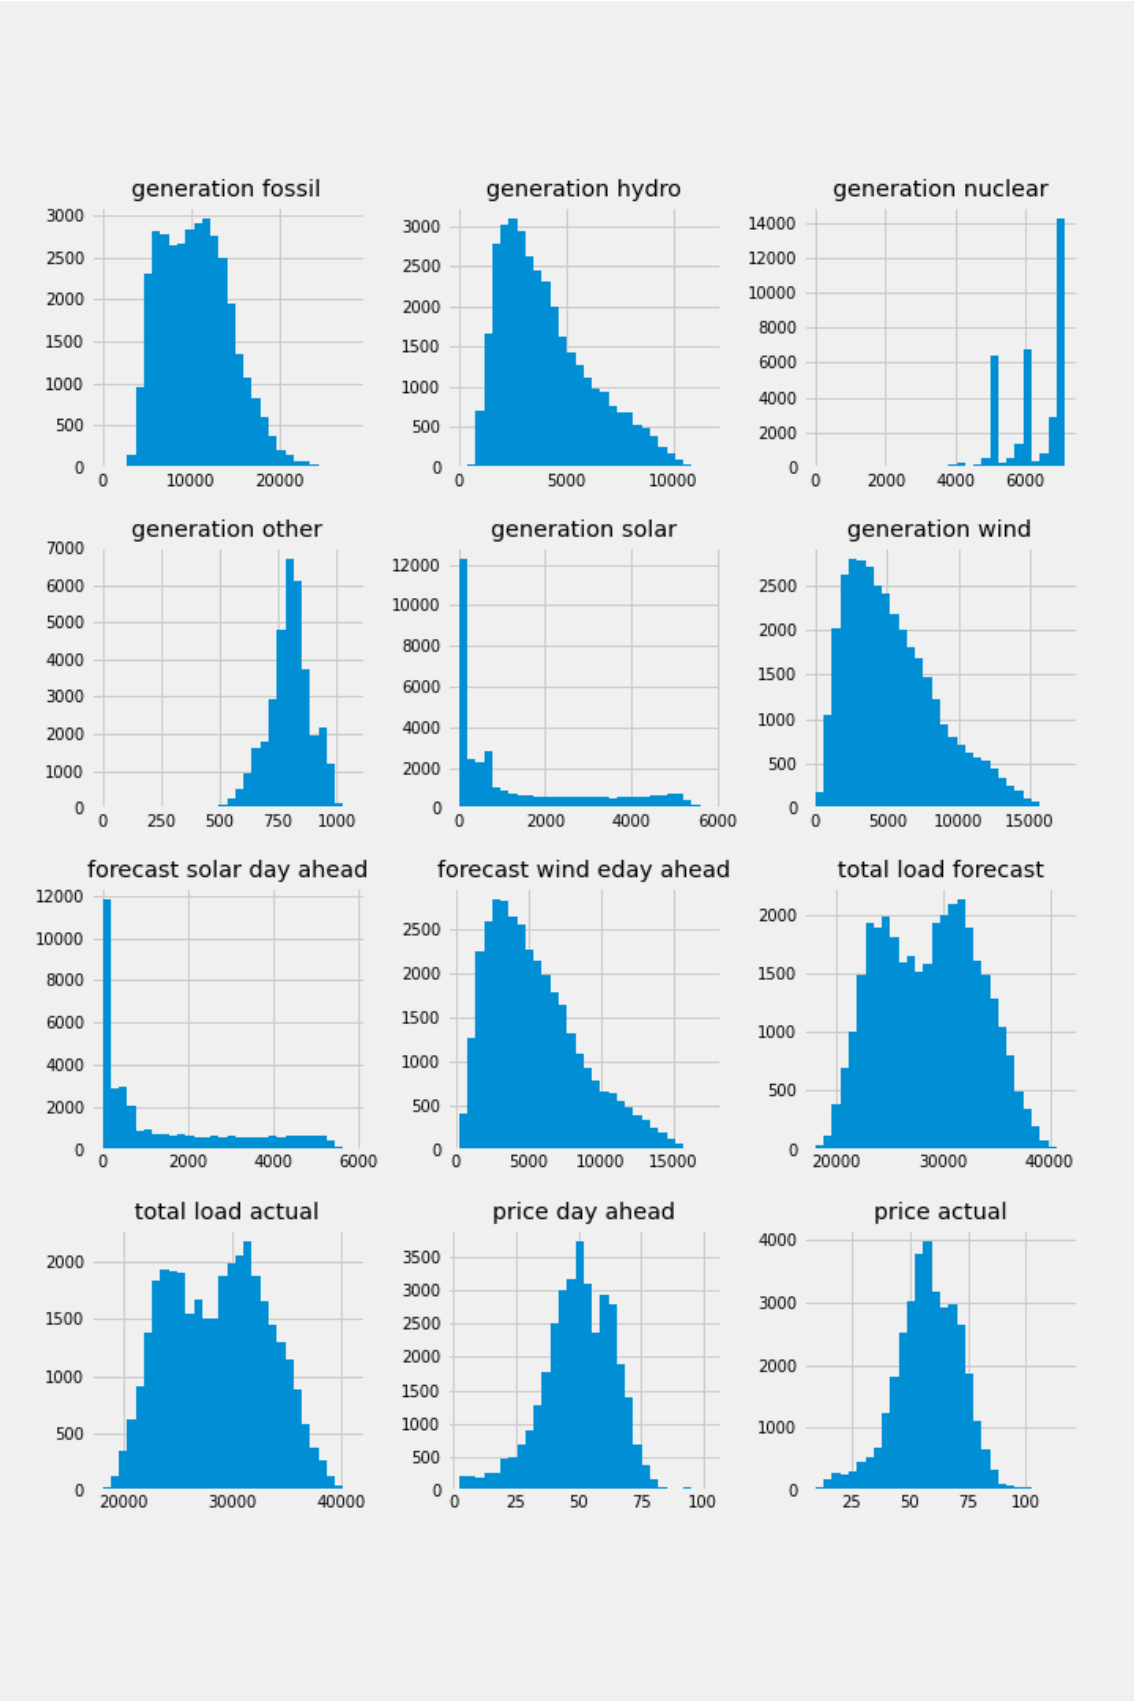

Img_02 . – Energy histograms_origin

6.b) DENSIDAD DE PROBABILIAD

El siguiente paso natural es estudiar desde los histogramas hacia las funciones de densidad de probabilidad, y cómo se distribuyen los datos.

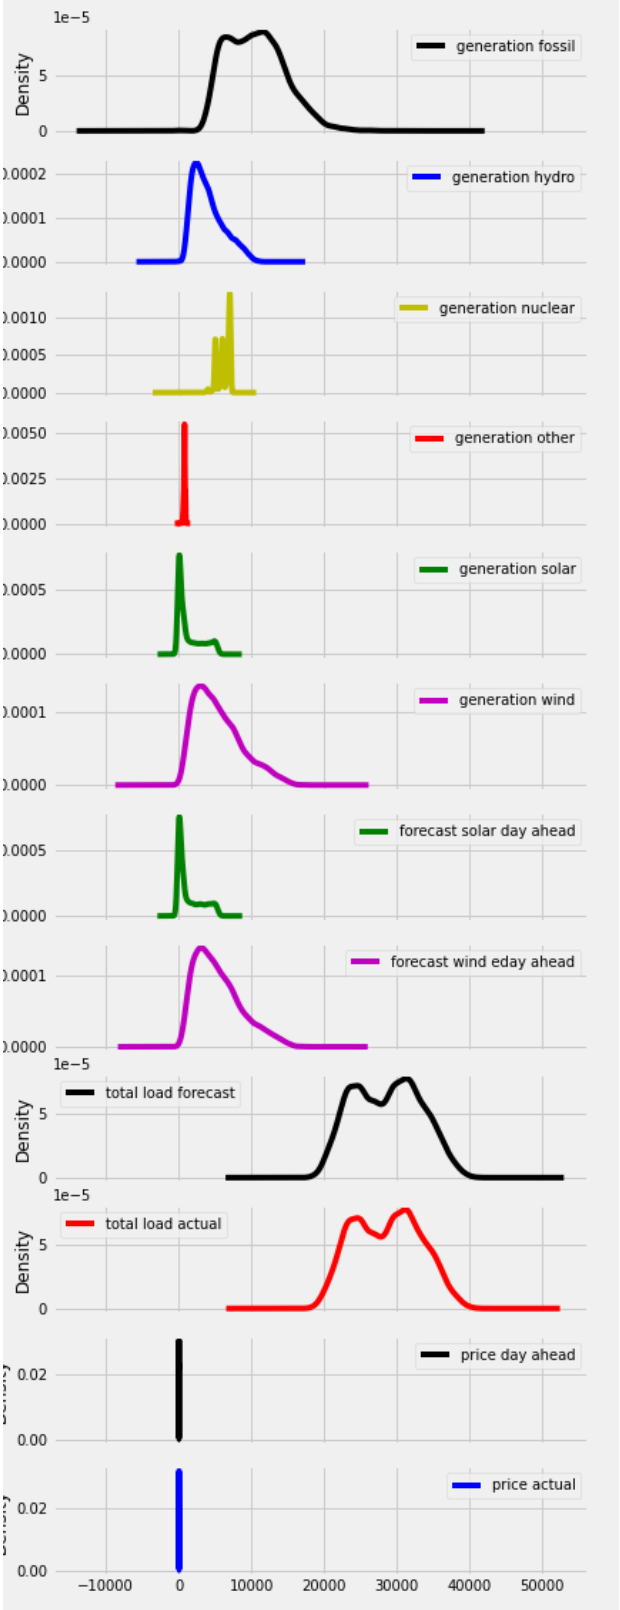

Img_03. – Energy KDE_origin

7.b) DIAGRAMA DE CAJAS

Para identificar mejor los valores anómalos o 'outlayers', una de las mejores herramienta de visualización que se dispone es el diagrama de cajas, y así, tener en cuenta como se filtrarán estos datos en cada atributo.

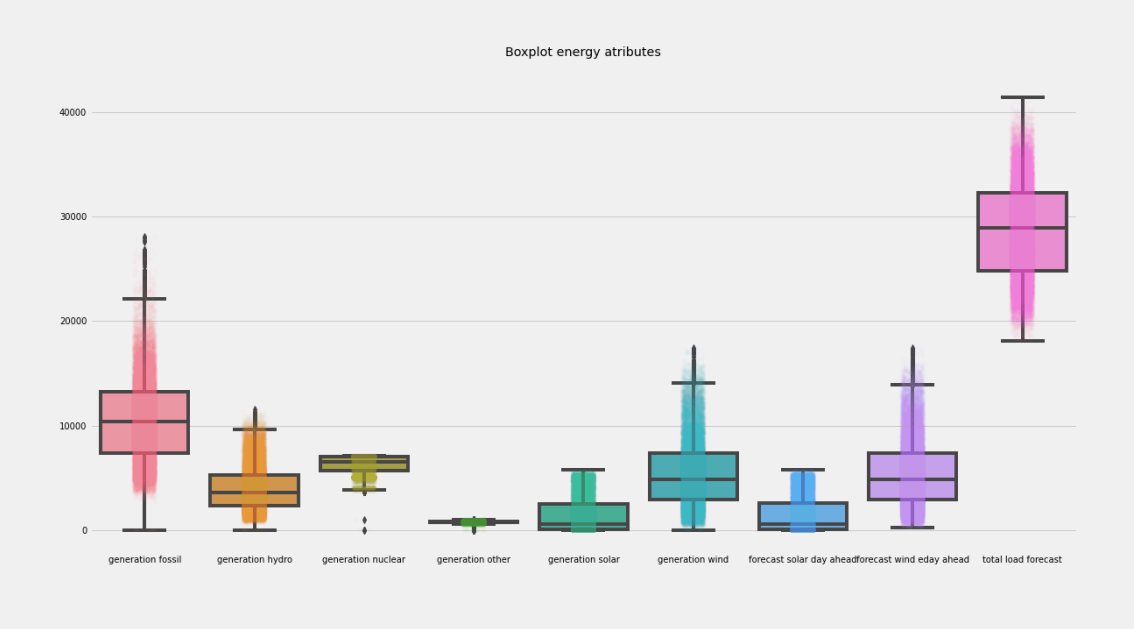

Img_04. – Energy_genertion_boxplot_origin

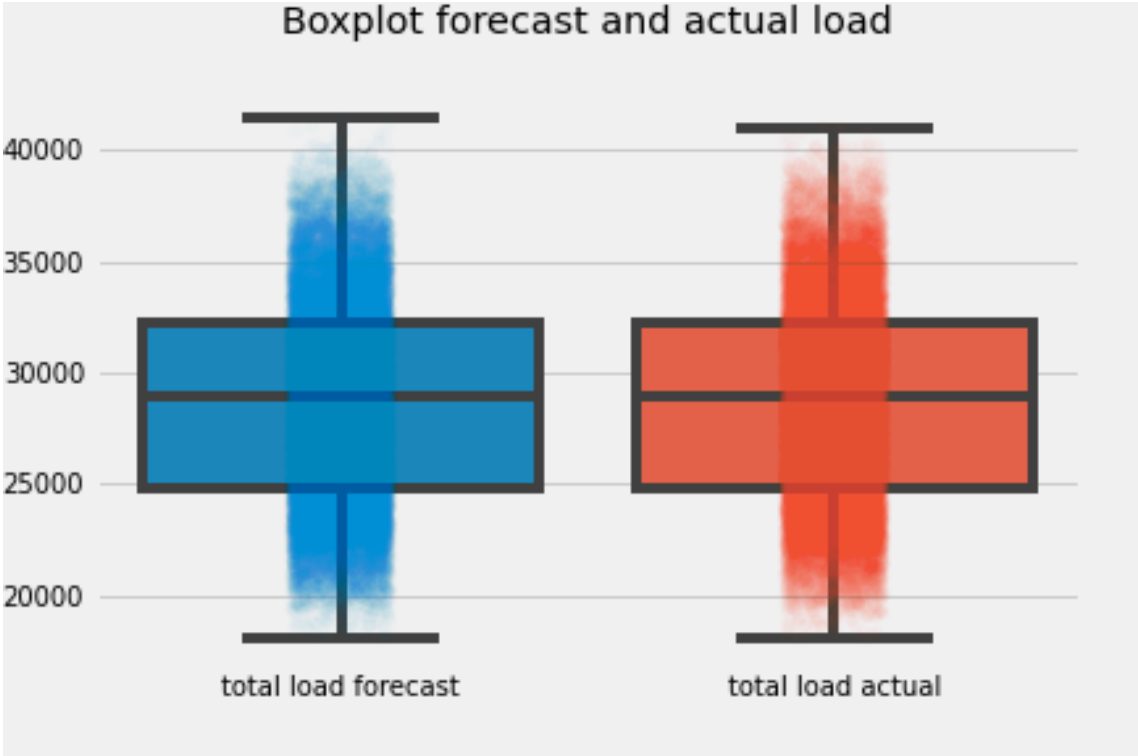

Img_05. – Energy load boxplot origin

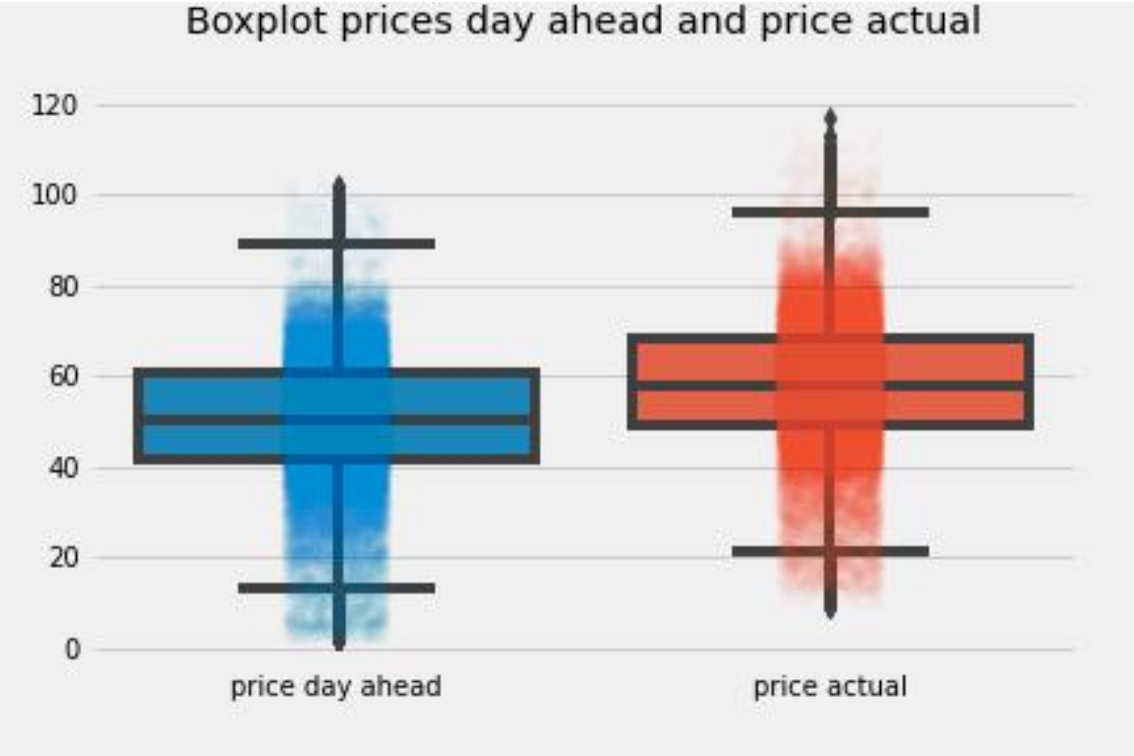

Img_06. – Energy price boxplot origin

8.b) TRATAMIENTO DE OUTLAYERS

Se crea una función específica para filtrar los valores anómalos de cada serie.

Esta función está dentro de un módulo propio 'functions_EDA.py'* que se ha importado junto con el resto de los paquetes, para optimizar su uso en los dataset que se trabajen en otro proyectos de exploración.

```
# columns are traversed and outlayer_drop function is executed
for i in energy.columns:
    print(i.upper())

    #function drop_outlayer
    energy = f_eda.drop_outlayers_df(energy, i)
    print('Delete', i,'outlayers, length dataframe is ',energy.shape[0])
    print('\n')
```

*Anexo: Module, functions_EDA.py

GENERATION FOSSIL
Delete generation fossil outlayers, length dataframe is 34891

GENERATION HYDRO
Delete generation hydro outlayers, length dataframe is 34582

GENERATION NUCLEAR
Delete generation nuclear outlayers, length dataframe is 34462

GENERATION OTHER
Delete generation other outlayers, length dataframe is 33723

GENERATION SOLAR
Delete generation solar outlayers, length dataframe is 33723

GENERATION WIND
Delete generation wind outlayers, length dataframe is 33330

FORECAST SOLAR DAY AHEAD
Delete forecast solar day ahead outlayers, length dataframe is 33330

FORECAST WIND EDAY AHEAD
Delete forecast wind eday ahead outlayers, length dataframe is 33156

TOTAL LOAD FORECAST
Delete total load forecast outlayers, length dataframe is 33156

TOTAL LOAD ACTUAL
Delete total load actual outlayers, length dataframe is 33156

PRICE DAY AHEAD
Delete price day ahead outlayers, length dataframe is 32562

PRICE ACTUAL
Delete price actual outlayers, length dataframe is 32229

9.b) CORRELACIÓN

Se visualizará las correlaciones lineales de dos en dos.

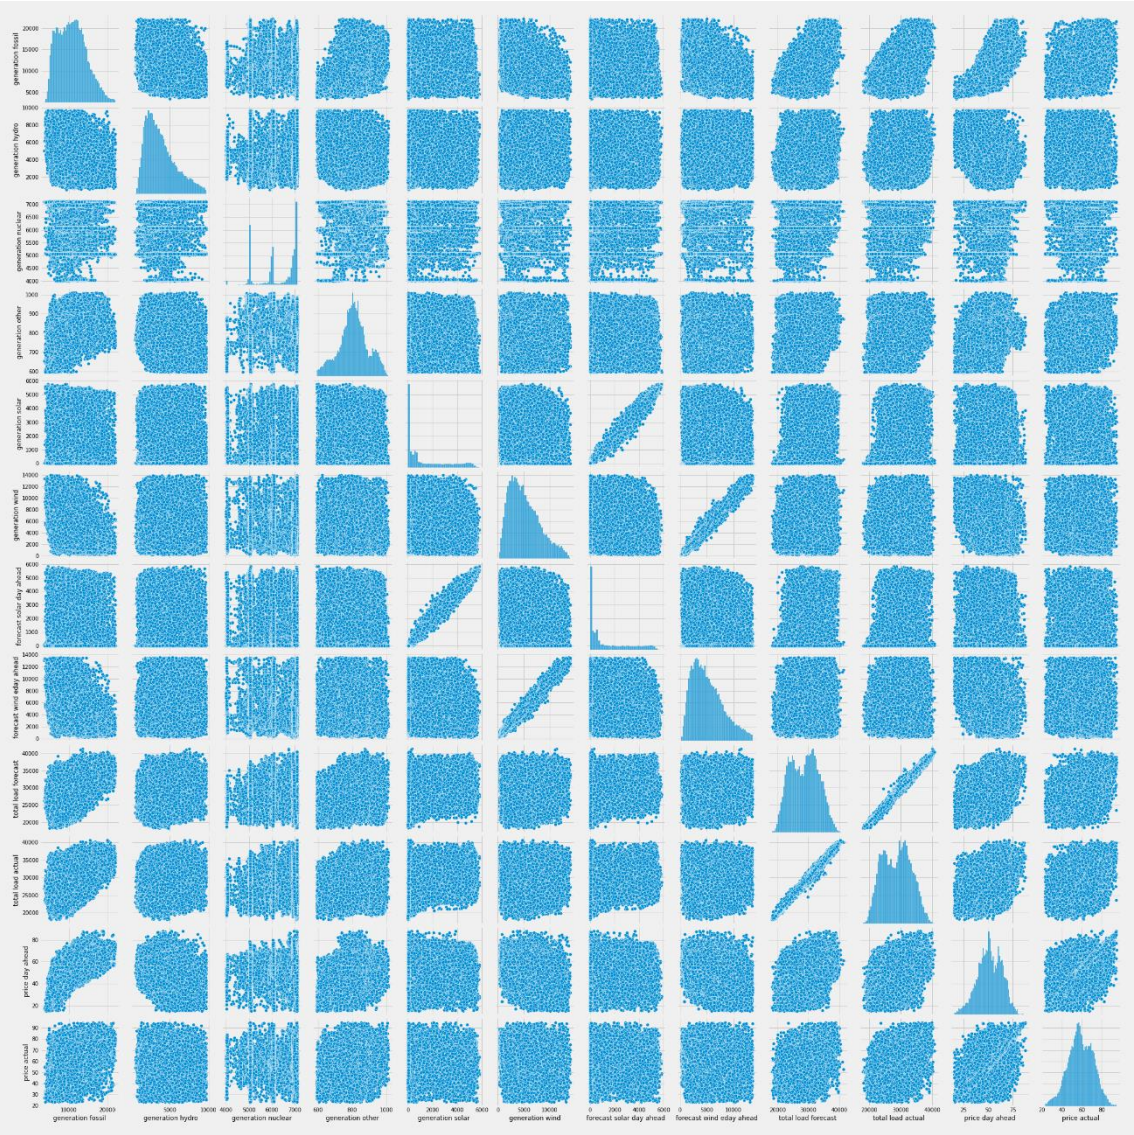

Img_07. – Energy pairplot origin

Aparte de las relaciones directas y lógicas que existen entre generación y estimación solar y eólica, así como en demanda y precio. Se puede observar que la generación fósil es la que tiene visualmente una correlación más evidente con la variable demanda y precio.

En este punto se van a medir las relaciones lineales que existen entre los diferentes atributos.

Se verifica numéricamente que la generación fósil es la que tiene una correlación lineal más fuerte con la variable demanda y precio. Y una relación inversa con la generación eólica.

Teniendo en cuenta que el dato que se desea averiguar a futuro es el precio por kW/hora, se ordenan las correlaciones lineales que tiene con el resto de atributos.

```
energy.corr()['price actual'].abs().sort_values(ascending=False)
```

```
price actual                1.000000
price day ahead             0.720350
generation fossil           0.483992
total load actual           0.418124
total load forecast         0.417587
generation other            0.217212
generation wind             0.170474
forecast wind eday ahead    0.169225
forecast solar day ahead    0.112777
generation solar            0.109201
generation nuclear          0.072682
generation hydro            0.032006
Name: price actual, dtype: float64
```

Se ha podido comprobar con el gráfico 'pairplot' y, ahora con el valor numérico que existen varias columnas con correlaciones lineales prácticamente iguales.

Se eliminarán del dataset para evitar la multicolinealidad una de ambas de las columnas implicadas; total load forecast, forecast wind eday ahead y forecast solar day ahead, y en este caso se mantendrán los valores reales.

Se elimina del dataset, la previsión (price day ahead) de precio por hora, ya que se dispone del precio final cerrado de consumo.

10.b) VISUALIZACIÓN DEL COMPORTAMIETNO DE LAS FUENTES DE ENERGÍA

En este punto se inicia la observación del comportamiento de los diferentes tipos de generación, y se utilizará gráfico de línea.

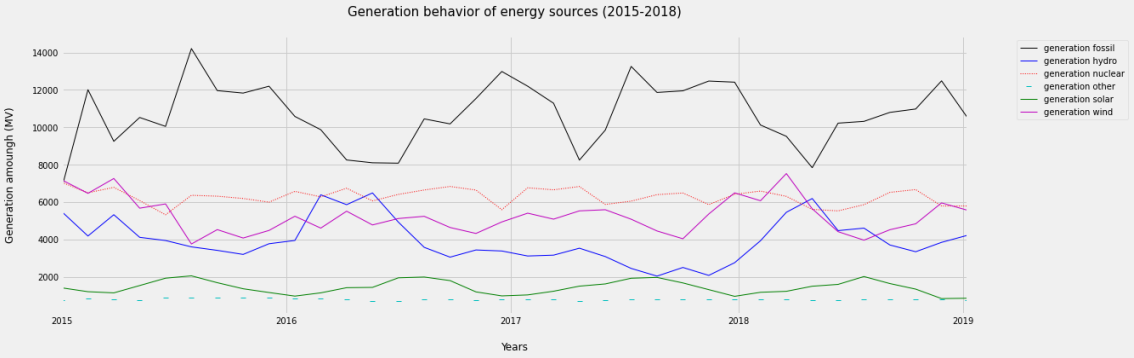

Img_08. – Generation behavior of energy sources(2015-2018)

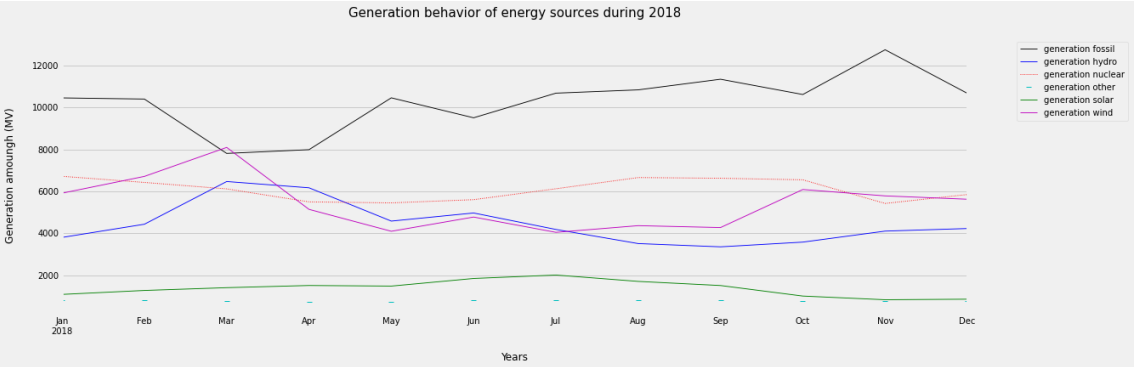

Img_09. – Generation behavior of energy sources during 2018

Con ambas gráficas se puede ver que la generación hidroeléctrica, la eólica y la solar son claramente estacionales.

La energía obtenida a través del sol tiene un ligero aumento de producción en los meses de verano y principios de otoño, y un descenso moderado en invierno.

La energía eólica tiene su pico de producción en primavera, importante cuota tanto en invierno como otoño, y un valle muy pronunciado en verano.

La época de mayor generación hídrica es en el periodo de primavera, se interpreta que es por ser la época de deshielo y lluvias. Podemos observar, por ejemplo, en la gráfica entre 2015 y 2018, que en el año 2017 no se obtuvo una importante producción en dicho periodo, por tanto, pudo darse un invierno de sequía, sin muchas precipitaciones.

El comportamiento de la energía fósil, parece que está fuertemente condicionado tanto a la eólica como a la hidroeléctrica, ya que su producción es inversa a la generación de estas. Esto denota que es una fuente programable y de rápida respuesta para cubrir la demanda.

Las 'otras' fuentes de energía y la nuclear, tiene un comportamiento muy estable dentro de la generación total.

Ahora se busca visualizar los pesos de los diferentes tipos de fuentes con un gráfico de barras acumulado, colocando en la base las más constantes y que tienen menos relación directa con el clima. Se utilizará las medias mensuales, y se pintará también línea de la demanda total media. Se elegirá el último año del que se dispone para visualizar la dimensión que representa cada origen de generación.

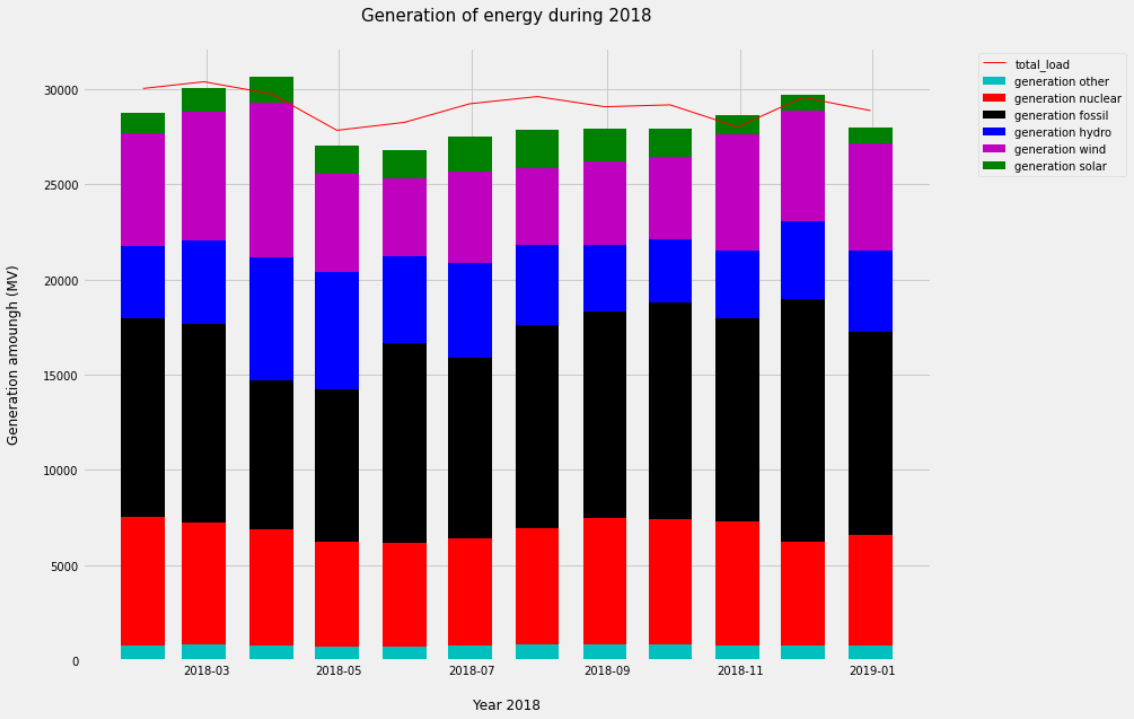

Img_10. – Generation of energy during 2018

11.b) DEMANDA Y PRECIO

En este punto se analizará dos de los atributos que determinan el 'negocio' energético; la demanda y el precio, revisándose en detalle.

Demanda (Load energy). Visualización de la demanda teniendo en cuenta diferentes lineas temporares.

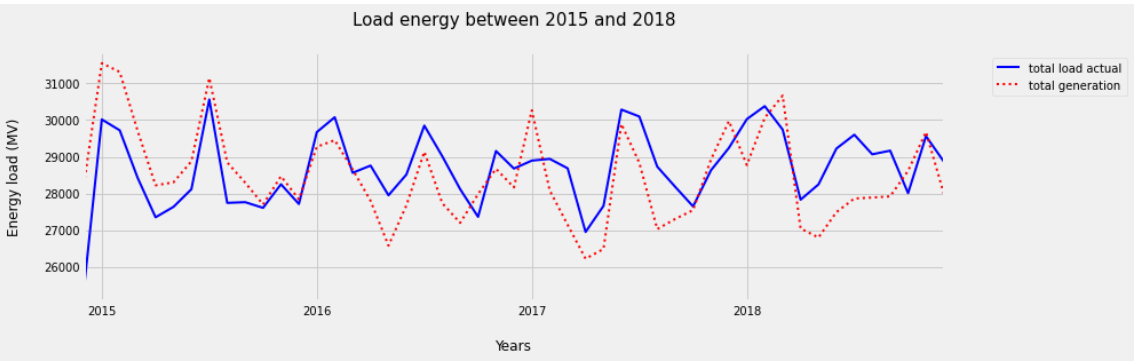

Img_11. – Load energy (2015 – 2018)

El comportamiento de la generación y la demanda se producen de forma ajustada, puesto que la energía es un recurso que no se puede almacenar. Cuando hay demanda la generación tiene que cubrirla.

Se utilizará los datos del último año para observar la demanda a lo largo de 2018, y se visualizan las fechas de los festivos nacionales para determinar el efecto de estas en el consumo.

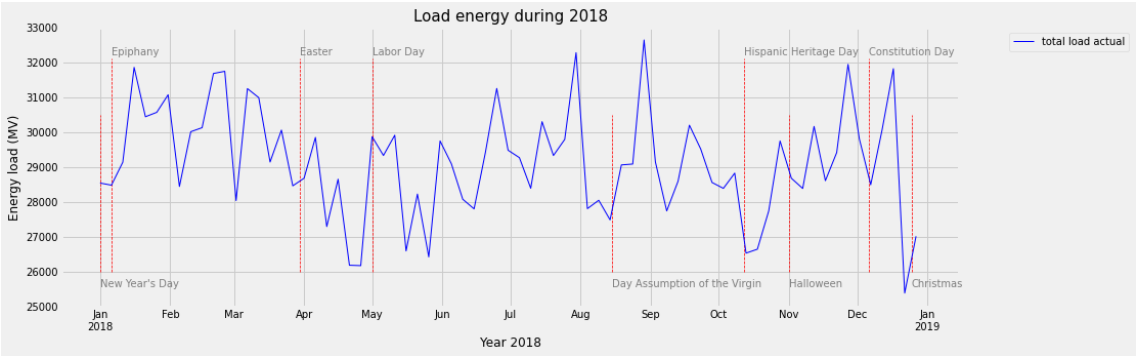

Img_12. – Load energy during 2018

Con esta gráfica se puede apreciar que existe un efecto directo en la demanda energética durante las fiestas y los periodos vacacionales.

Ahora con una gráfica de calor, se visualizará la demanda durante el intervalo de una semana, para poder observar las horas de más pico y valle energético.

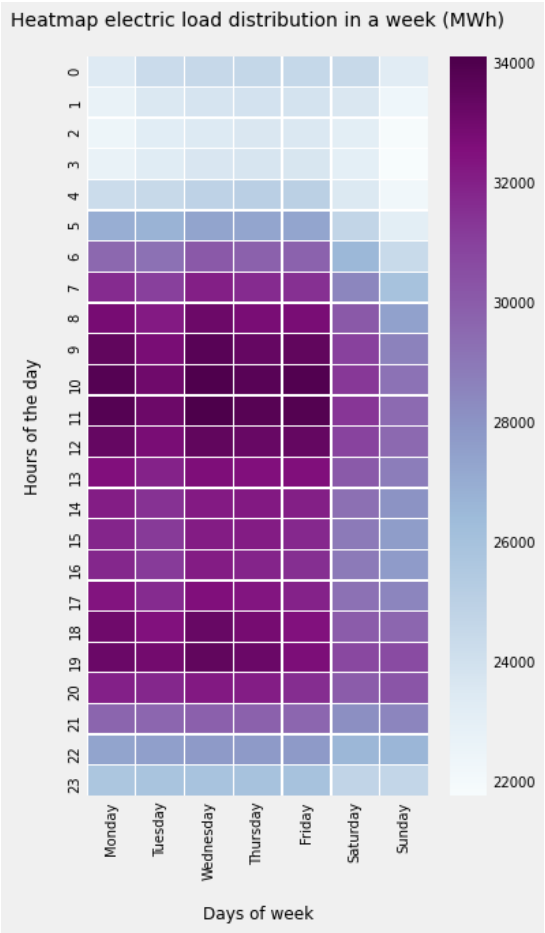

Img_13. – Heatmap electric LOAD in a week

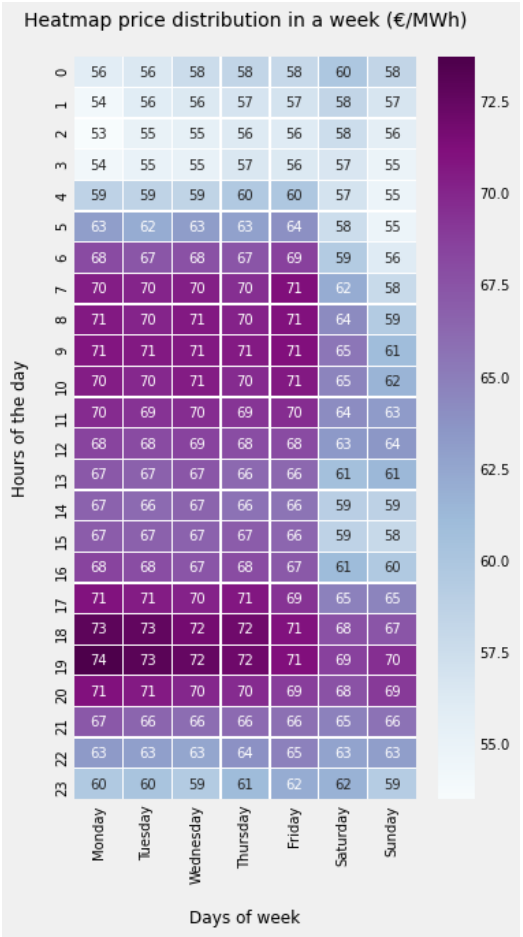

Img_14. – Heatmap electric PRICE in a week

Precio. Para el precio que es el atributo 'target' para establecer el modelo de este exploratorio, también se va hacer uso de un mapa de calor.

Las oscilaciones de los precios en los intervalos horarios durante una semana son prácticamente iguales a las variaciones de demanda energética en dicho momento.

En ambos gráficos se muestra con claridad que el pico de mayor uso energético es de lunes a jueves de 7:00a 11:00h y, por la tarde, entre las 17:00 y 20:00h.

Durante el horario laboral existe una alta demanda ,y el momento de menor precio es por las noche entre la 1:00 y las 3:00h.

Visualizamos la fluctuación del precio a lo largo de todo un día, teniendo en cuenta los 7 días de la semana.

Visualizamos la fluctuación del precio a lo largo de todo un día, teniendo en cuenta los 7 días de la semana.

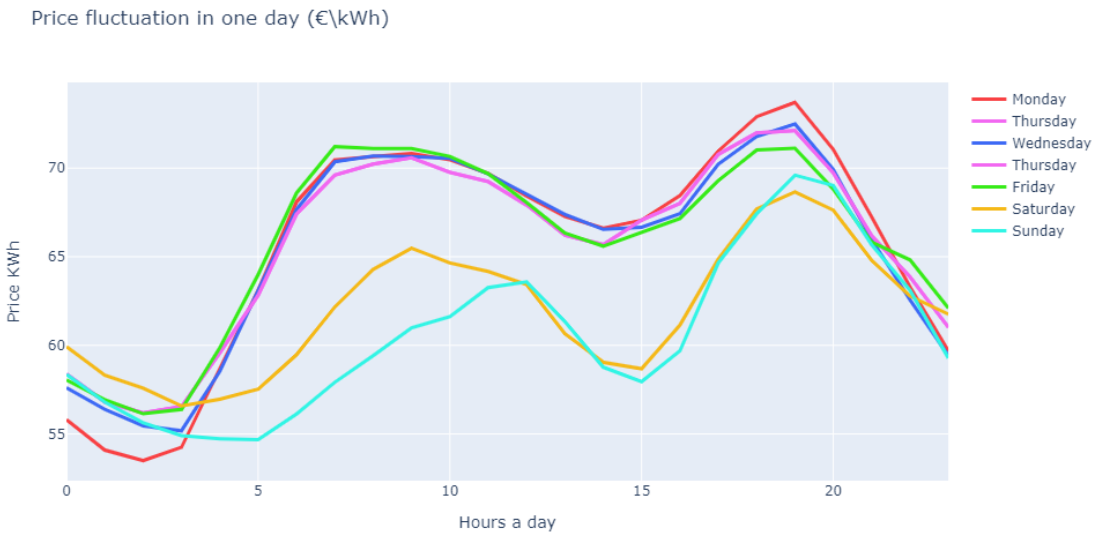

Img_15. – Price fluctuation in one day (€/kWh)

WEATHER

1.c) DESCARGA DE FICHERO

Se importa fichero '.csv' de datos climatológicos, y en este paso se realizará la manipulación correspondiente al DataFrame 'weather'.
Se modifica el tipo de dato de la serie temporal a numpy.datetime64 manteniendo el 'utc', aunque se desea utilizar el dato de fecha/hora como índice puesto que será el atributo por el que se vincule ambos datasets, de momento se mantiene el generado automáticamente por números correlativos enteros para realizar diferentes operaciones de limpieza.

La dimensión inicial del dataset es de 178396 registros y 17 columnas.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 178396 entries, 0 to 178395
Data columns (total 10 columns):
 #   Column          Non-Null Count   Dtype
---  ------          --------------   -----
 0   time            178396 non-null  datetime64[ns]
 1   city_name       178396 non-null  object
 2   temp            178396 non-null  float64
 3   pressure        178396 non-null  int64
 4   humidity        178396 non-null  int64
 5   wind_speed      178396 non-null  int64
 6   water_collected  178396 non-null  float64
 7   clouds_all      178396 non-null  int64
 8   weather_id      178396 non-null  int64
 9   weather_main    178396 non-null  object
dtypes: datetime64[ns](1), float64(2), int64(5), object(2)
memory usage: 13.6+ MB
```

Se observa que no hay registros con valores null.

Se elimina los atributos de 'temp_min' y 'temp_max', puesto que disponemos de un valor general de temperatura durante ese intervalo de hora.

La columna categórica de 'weather_description' debido a que tenemos una clasificación principal del 'tiempo' se elimina del conjunto de datos, y también 'weather_icon' que los valores que tiene la API como imagen de representación del tiempo.

Se descarta la columna de orientación del viento puesto que es un atributo que sería importante dependiendo de la ubicación del parque eólico y los flujos de corrientes de la zona, y como inciden en la generación con respecto a otros parques, pero no se considerará en este caso a nivel nacional.

2.c) AGRUPACIÓN VALORES RECOGIDA DE AGUA

Se revisa el montante de los datos de lluvia recogida en '1h'y en las 3h (mm/h), para cuantificar el volumen y su peso en el conjunto de datos. Teniendo en cuenta que estos datos están recogiendo la información de agua en sólo 5 puntos de todo el territorio y su dimensión no es significativa, se decide acumularlas con los registros de lluvia que existen de 1h.

Se acumulan en una sola serie, se con el nombre de 'water_collected'.

3.c) CONVERSOR DE TEMPERATURA

Los datos de la serie de temperatura están registrados en grados 'kelvin', se realiza conversión a grados 'celsius' que son la métrica con la que estamos más familiarizados.

4.c) HISTOGRAMAS WEATHER

En este punto se explorará los datos de cada columna, y eliminar datos fuera de rango.

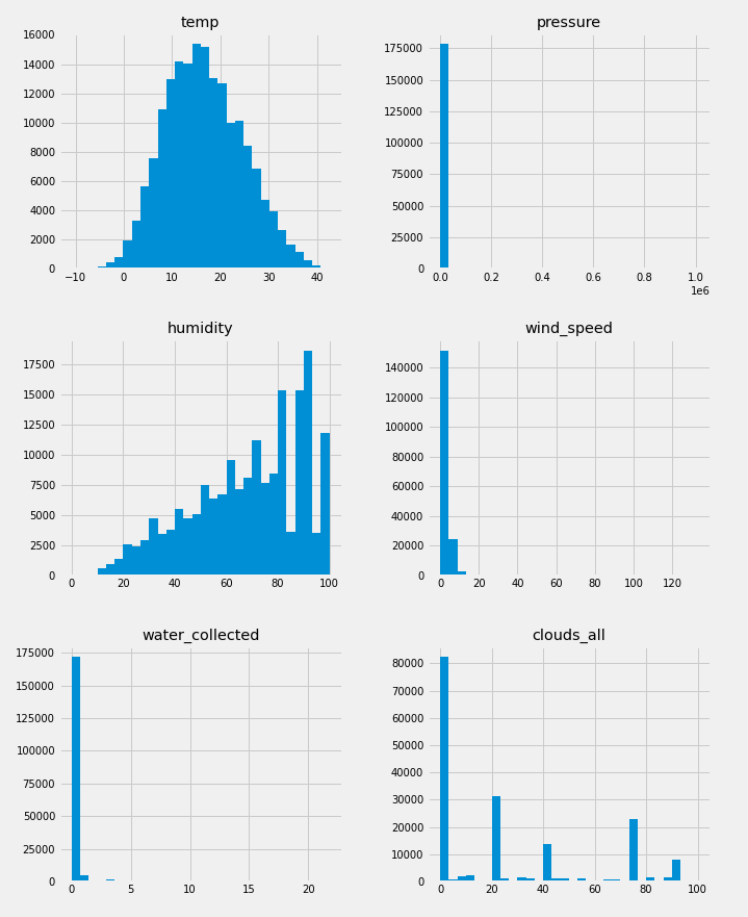

Img_16 . – Weather histograms origin.

5.c) DIAGRAMAS DE CAJAS

Una vez visto los histogramas de las columnas, existe varios atributos que destacan por su oscilación de valores:

1.- Pressure

2.- Wind Speed

2.- Water collected

El gráfico de caja nos dará más información a la hora de identificar 'outlayers' de las columnas de 'weather', así se podrán limpiar para obtener el dataset final.

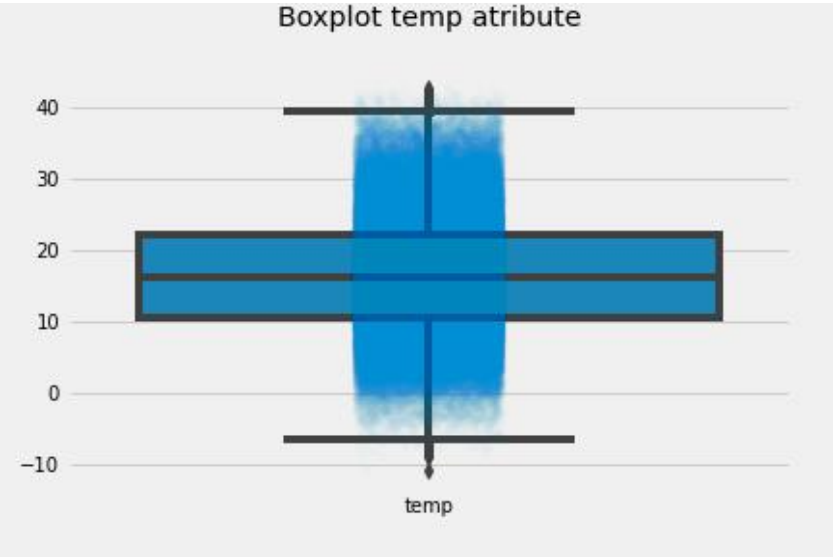

Img_17 . – Weather. Temperature boxplot origin.

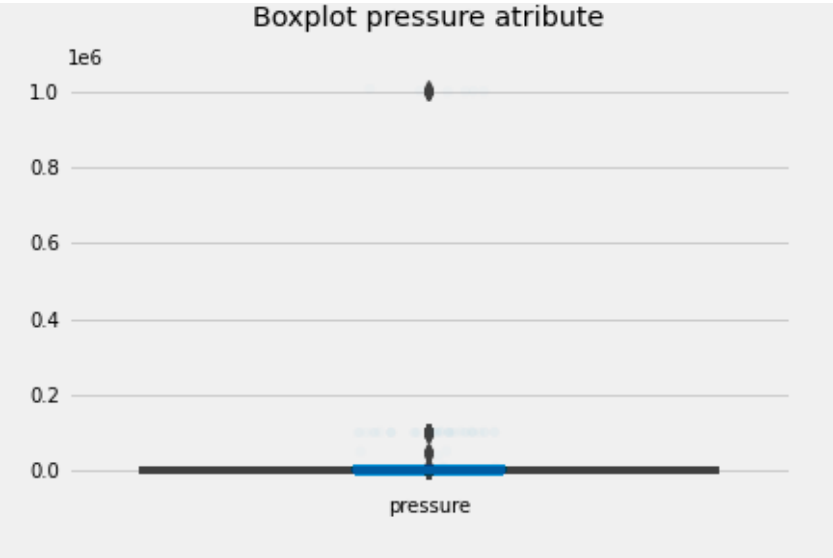

Img_18 . – Weather. Pressure boxplot origin.

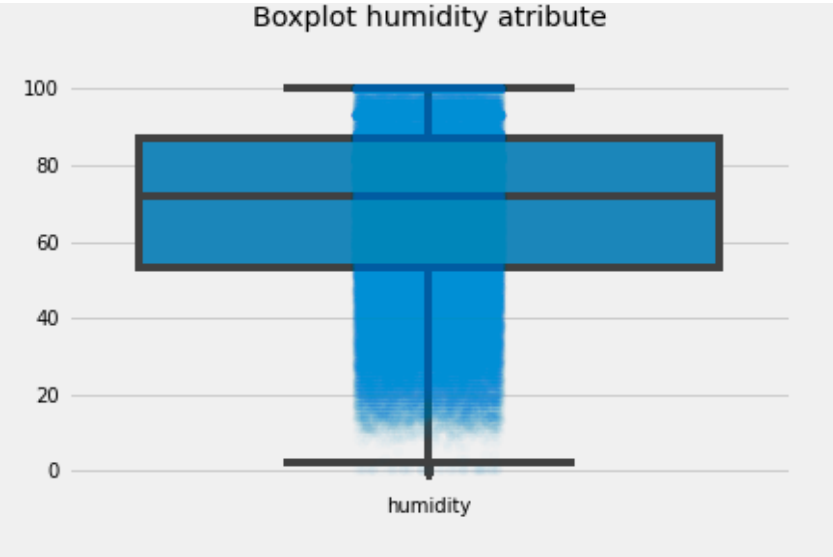

Img_19 . – Weather. Humidity boxplot origin.

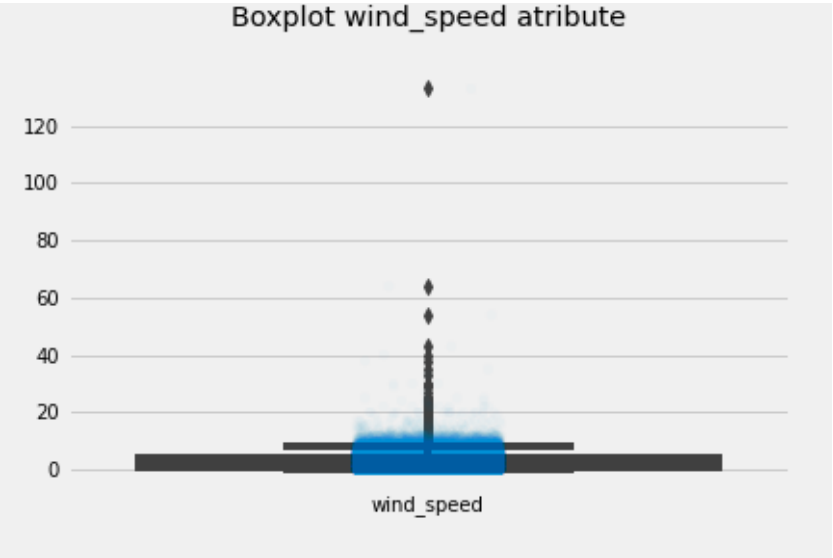

Img_20 . – Weather. Wind seed boxplot origin.

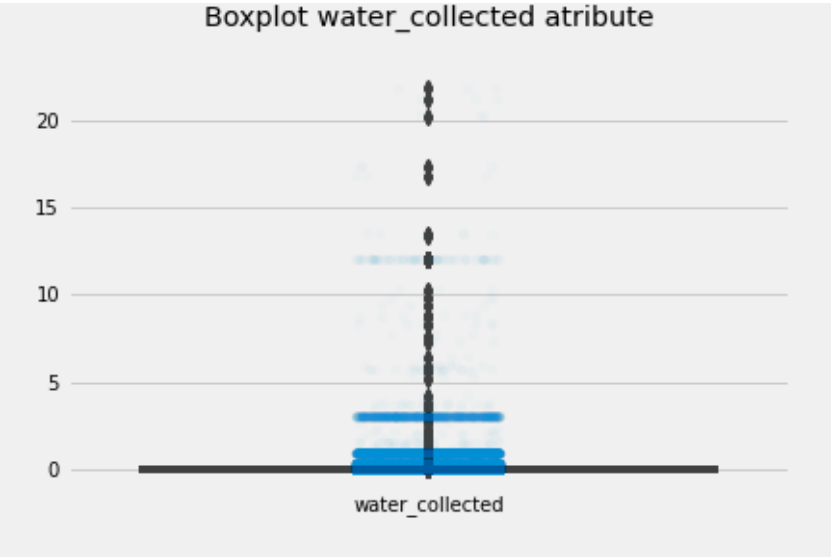

Img_21 . – Weather. Water collected seed boxplot origin.

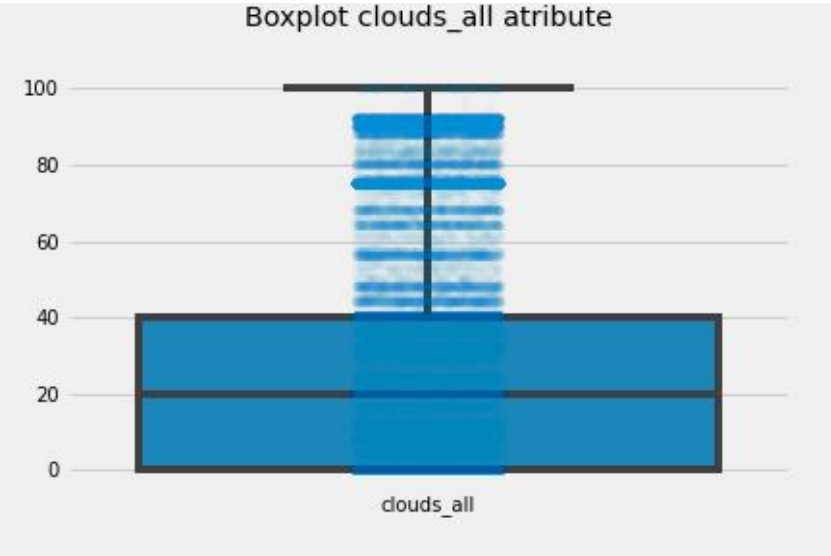

Img_22 . – Weather. Cloudiness percentage boxplot origin.

Según el gráfico de cajas hay un claro atributo que tiene valores que pueden llegar a distorsionar en exceso el resultado de la computación.

La serie 'pressure' posee outlayers con valores elevadísimos. Al visualizar los datos estadísticos de cada atributo, en 'pressure' se observa que tiene una desviación de casi 6000hPa. cuando su media, su mediana y los cuartiles 25% y 75% están entorno a 1.000 hPa.

6.c) TRATAMIENTO DE OUTLAYERS

Al igual que en el conjunto de datos de 'energy' se hace unos de la función 'drop_outlayers_df()' del módulo 'functions_EDA.py'*, sobre las columnas numéricas, no sobre las columnas categórica que se han eliminado previamente.

```
#Delete rows have outlayers, use functions_EDA module
for i in weather.columns[2:8]:
    print(i.upper())
    weather = f_eda.drop_outlayers_df(weather, i)
    #weather = drop_outlayers_df(weather,i)
    print('Delete', i,'outlayers, length dataframe is ',weather.shape[0])
    print('\n')
```

```
TEMP
Delete temp outlayers, length dataframe is  178203


PRESSURE
Delete pressure outlayers, length dataframe is  166406


HUMIDITY
Delete humidity outlayers, length dataframe is  166391


WIND_SPEED
Delete wind_speed outlayers, length dataframe is  164239


WATER_COLLECTED
Delete water_collected outlayers, length dataframe is  145433


CLOUDS_ALL
Delete clouds_all outlayers, length dataframe is  124995
```

6.c) DENSIDAD DE PROBABLIDAD, SIN OUTLAYERS.

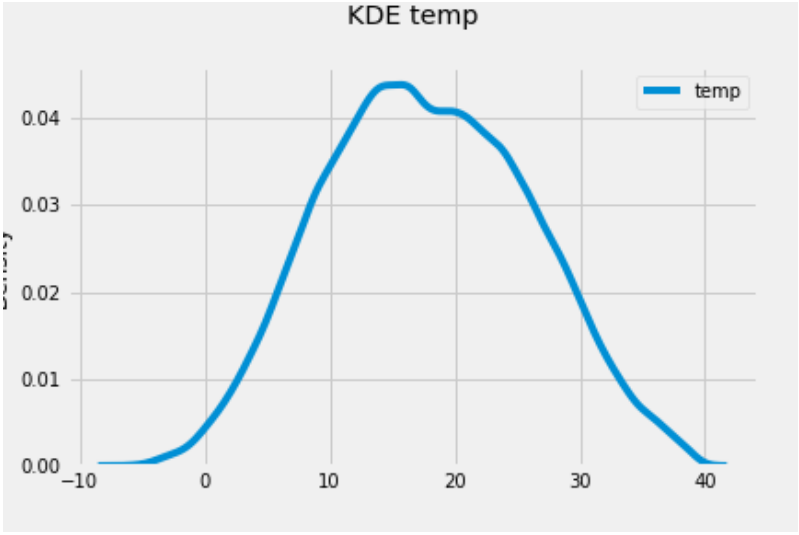

Img_ 23. – Weather. Temperature KDE.

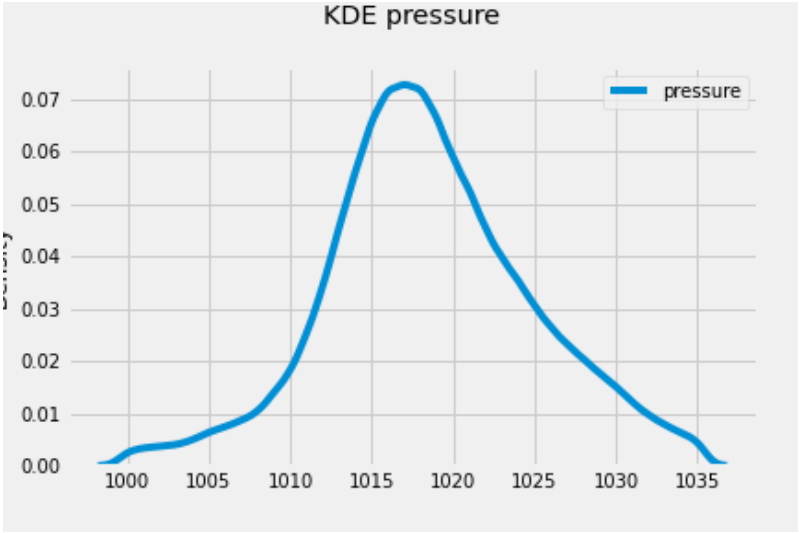

Img_24 . – Weather. Pressure KDE.

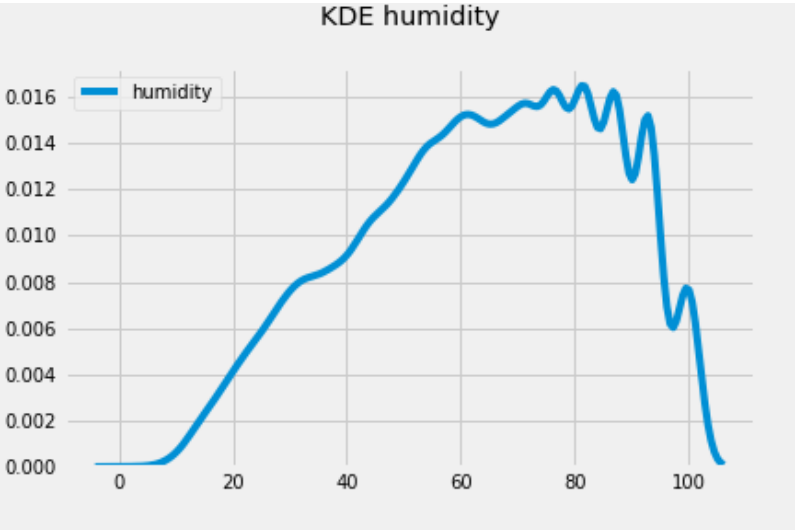

Img_25 . – Weather. Humidity KDE.

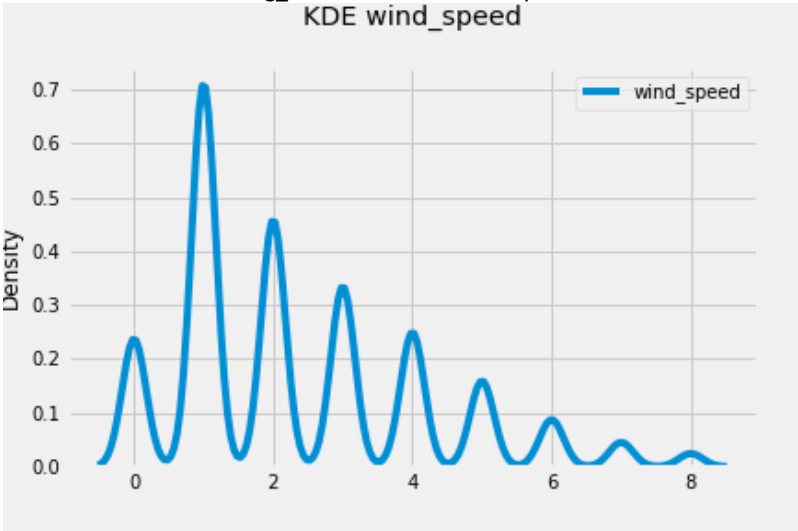

Img_20 . – Weather. Wind seed KDE.

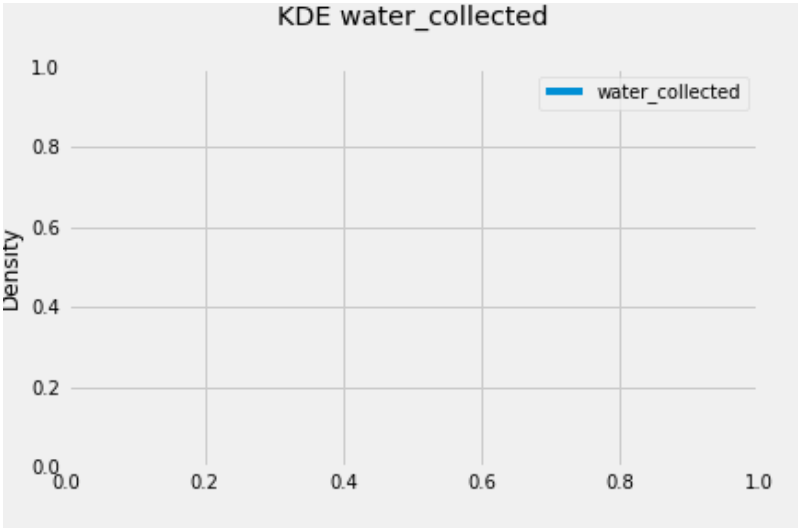

Img_21 . – Weather. Water collected seed KDE.

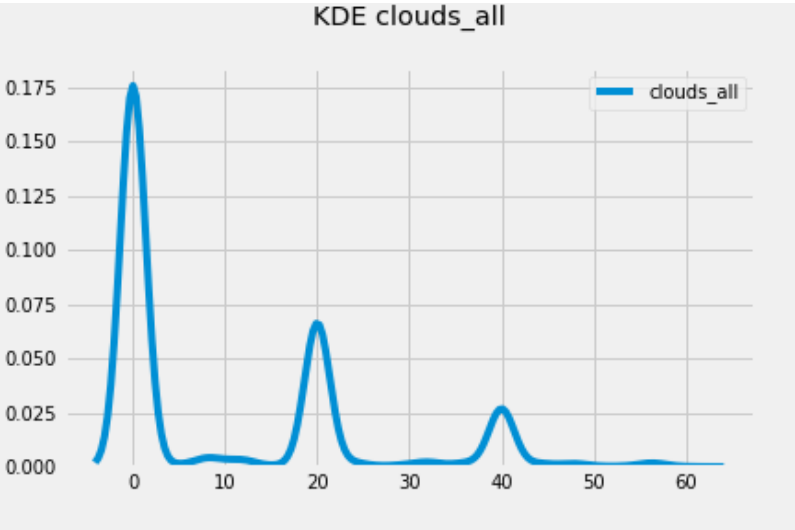

Img_22 . – Weather. Cloudiness percentage KDE.

La serie 'water_collected' del dataframe después de eliminar los outlayers tiene todos los registros a '0', no aportará valor al modelo. Se elimina del conjunto de atributos del dataset.

6.d) VISUALIZACIÓN DE ATRIBUROS FINAL (PAIRPOLT)

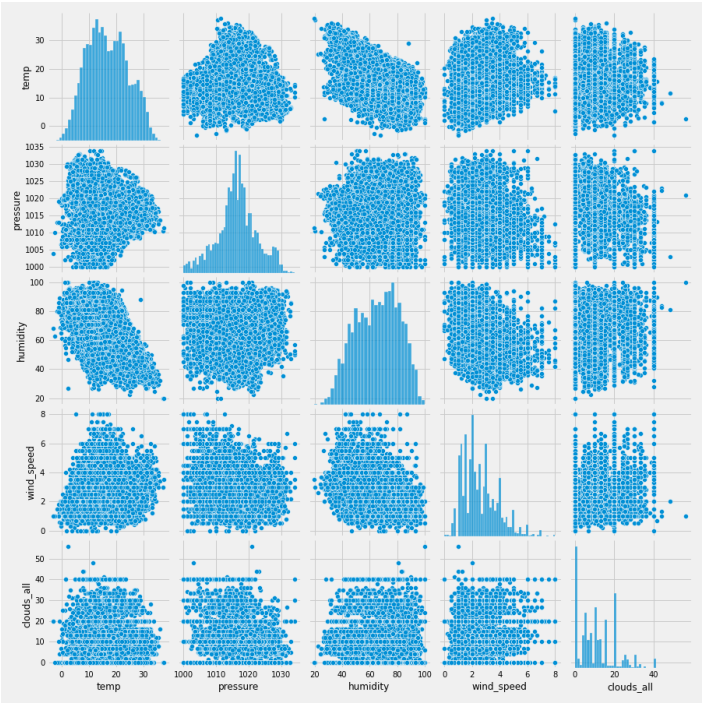

Img_23 . – Weather. Pairplot attributes.

DATAFRAME FINAL – MERGE ENERGY Y WEATHER

1.d) INDICES

En este paso se comprobará los índices y se tratarán para que en ambos datasets coincidan, con la finalidad de unirlos a través de esta columna.

Como se había comentado al inicio del estudio del dataset 'weather', la fecha y hora será la columna por la que se realizará la unión con el dataset 'energy'.

En este momento se fija como Índex la serie temporal.

Se comprueba que en el conjunto de datos de índices de este DataFrame no son únicos, y por tanto, se explora la naturaleza de estos registros.

```
weather.index.is_unique
```

```
False
```

```
weather.shape[0], energy.shape[0]
```

```
(124995, 32229)
```

Se seleccionan 2 índices aleatorios, para su observación.

```
weather.loc[np.random.choice(weather.index, size=2),:]
```

[366]:

time	time	city_name	temp	pressure	humidity	wind_speed	water_collected	clouds
2018-01-15 19:00:00	2018-01-15 19:00:00	Valencia	11.15	1025	53	1	0.0	
2018-01-15 19:00:00	2018-01-15 19:00:00	Madrid	5.91	1027	70	3	0.0	
2018-01-15 19:00:00	2018-01-15 19:00:00	Barcelona	8.65	1022	75	4	0.0	
2018-01-15 19:00:00	2018-01-15 19:00:00	Seville	10.18	1028	76	3	0.0	
2018-04-06 02:00:00	2018-04-06 02:00:00	Valencia	11.15	1017	81	2	0.0	
2018-04-06 02:00:00	2018-04-06 02:00:00	Madrid	9.15	1013	76	2	0.0	
2018-04-06 02:00:00	2018-04-06 02:00:00	Bilbao	12.83	1009	55	4	0.0	
2018-04-06 02:00:00	2018-04-06 02:00:00	Barcelona	9.15	1017	93	1	0.0	
2018-04-06 02:00:00	2018-04-06 02:00:00	Seville	12.33	1011	67	3	0.0	

Los registros del dataset 'weather' que se ha descargado para el EDA, recogen sólo información climatológica de 1 a 5 puntos distintos (las ciudades de Valencia, Madrid, Bilbao, Barcelona, Sevilla) del territorio. Por tanto, en el mismo intervalo de día/hora se pueden llegar a tener 5 filas repetidas con ese índice pero con diferentes valores en el resto de atributos.

En este momento se tiene que estudiar el mejor criterio a la hora de eliminar los registros duplicados del dataset 'weather' para que coincida con los indices de 'energy'.

Una de las opciones sería seleccionar una de las ciudades, por ejemplo 'Madrid' puesto que se encuentra en el punto central y a una altura intermedia del país, y eliminar el resto de filas que tienen duplicado el índice.

Pero se considera más interesante a la hora de descartar las duplicidades del índice, agrupándolos por su índice y extrayendo sus valores medios según los fenómenos atmosféricos.

```
#unify values attributes with the same index
for index, value in weather.time.items():
   #print(value) #indexDateTime == values
   #print(weather.loc[value,:]) #DataFrame rows with the same index
   #print(type(weather.loc[value,:]))
   s_means = weather.loc[value,weather.columns[2]:weather.columns[7]].mean() #
Serie with means of attributes

   if isinstance(weather.loc[value,:], pd.DataFrame):
      for column in weather.columns[2:-2]:
         #print(s_means[column])
         weather.loc[value,column] = s_means[column]

   #print('\n')
```

Una vez los datos del mismo índice están unificados, se eliminarán los duplicados manteniendo el primer registro, y se elimina la columna con la se ha manipulado el dataset, que coincide con el IndexDateTime.

time	temp	pressure	humidity	wind_speed	water_collected	clouds_all
2014-12-31 23:00:00	3.0	1018.0	88.5	4.0	0.0	0.0
2015-01-01 00:00:00	1.0	1023.7	91.3	2.7	0.0	0.0
2015-01-01 01:00:00	-3.3	1002.0	78.0	0.0	0.0	0.0
2015-01-01 02:00:00	-3.6	1018.5	87.5	0.5	0.0	0.0
2015-01-01 03:00:00	-3.4	1018.5	87.5	0.5	0.0	0.0

Antes de iniciar la unión de los dos conjuntos de datos, verificamos si los índices son únicos.

```
weather.info()
```

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 34292 entries, 2014-12-31 23:00:00 to 2018-12-13 18:00:00
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype  
---  ------          --------------  -----  
 0   temp            34292 non-null  float64
 1   pressure        34292 non-null  float64
 2   humidity        34292 non-null  float64
 3   wind_speed      34292 non-null  float64
 4   water_collected  34292 non-null  float64
 5   clouds_all      34292 non-null  float64
dtypes: float64(6)
```

Verificamos cuantos Nan_values y que porcentaje de valores a '0' cero hay en cada columna.

```
weather.isnull().any()
```

```
temp             False
pressure         False
humidity         False
wind_speed       False
water_collected    False
clouds_all       False
dtype: bool
```

```
f_eda.percentage_zeros_columns(weather)
```

```
PERCENTAGE ZERO_VALUES OF COLUMNS DATAFRAME:

0.- temp : 0.017 %

1.- pressure : 0.0 %

2.- humidity : 0.0 %

3.- wind_speed : 0.321 %

4.- water_collected : 100.0 %

5.- clouds_all : 22.76 %
```

2.d) UNIÓN DE LOS CONJUNTOS DE DATOS ‘ENERGY’ Y ‘WEATHER’

A partir de ahora se juntan los dos dataframes creando un nuevo dataframe utilizando los índices que coinciden. Descartamos las filas que no coinciden en ambos conjuntos dado que tenemos muchos registros y podemos descartar directamente los generarán ‘missing values’.

```
df = weather.merge(energy, left_on=weather.index, right_on=energy.index, how='inner')
```

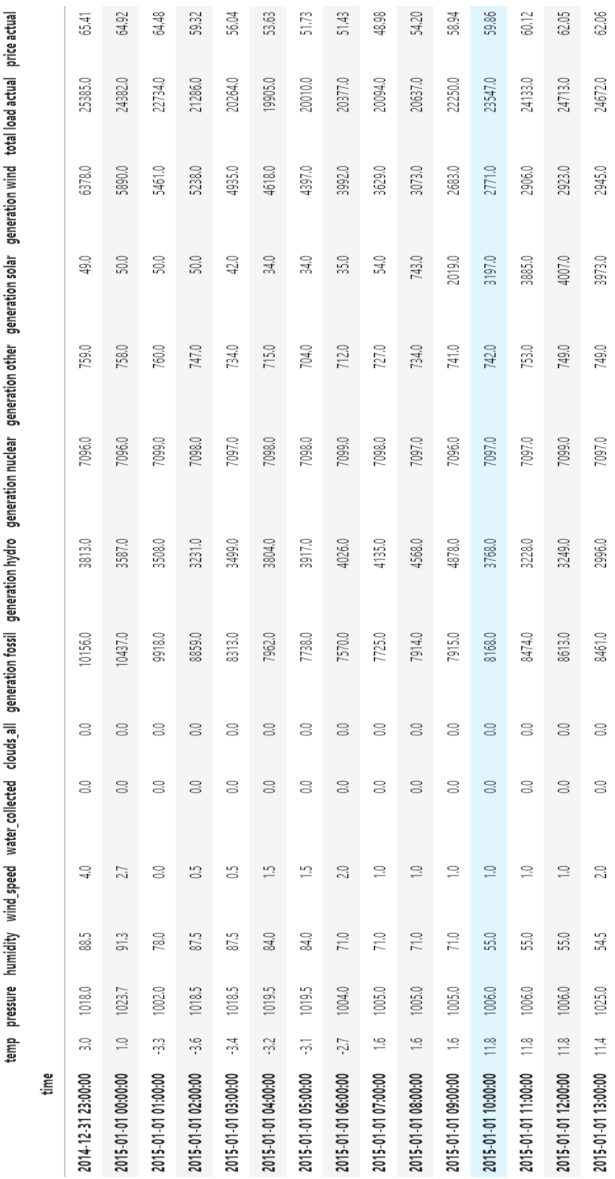

time	temp	pressure	humidity	wind_speed	water_collected	clouds_all	generation fossil	generation hydro	generation nuclear	generation other	generation solar	generation wind	total load actual	price actual
2014-12-31 23:00:00	3.0	1018.0	88.5	4.0	0.0	0.0	10156.0	3813.0	7096.0	759.0	49.0	6378.0	25385.0	65.41
2015-01-01 00:00:00	1.0	1023.7	91.3	2.7	0.0	0.0	10437.0	3587.0	7096.0	758.0	50.0	5890.0	24382.0	64.92
2015-01-01 01:00:00	-3.3	1002.0	78.0	0.0	0.0	0.0	9918.0	3508.0	7099.0	760.0	50.0	5461.0	22734.0	64.48
2015-01-01 02:00:00	-3.6	1018.5	87.5	0.5	0.0	0.0	8859.0	3231.0	7098.0	747.0	50.0	5238.0	21286.0	59.32
2015-01-01 03:00:00	-3.4	1018.5	87.5	0.5	0.0	0.0	8313.0	3499.0	7097.0	734.0	42.0	4935.0	20264.0	56.04
2015-01-01 04:00:00	-3.2	1019.5	84.0	1.5	0.0	0.0	7962.0	3804.0	7098.0	715.0	34.0	4618.0	19905.0	53.63
2015-01-01 05:00:00	-3.1	1019.5	84.0	1.5	0.0	0.0	7738.0	3917.0	7098.0	704.0	34.0	4397.0	20010.0	51.73
2015-01-01 06:00:00	-2.7	1004.0	71.0	2.0	0.0	0.0	7570.0	4026.0	7099.0	712.0	35.0	3992.0	20377.0	51.43
2015-01-01 07:00:00	1.6	1005.0	71.0	1.0	0.0	0.0	7725.0	4135.0	7098.0	727.0	54.0	3629.0	20994.0	48.98
2015-01-01 08:00:00	1.6	1005.0	71.0	1.0	0.0	0.0	7914.0	4568.0	7097.0	734.0	743.0	3073.0	20637.0	54.20
2015-01-01 09:00:00	1.6	1005.0	71.0	1.0	0.0	0.0	7915.0	4878.0	7096.0	741.0	2019.0	2683.0	22250.0	58.94
2015-01-01 10:00:00	11.8	1006.0	55.0	1.0	0.0	0.0	8168.0	3768.0	7097.0	742.0	3197.0	2771.0	23547.0	59.86
2015-01-01 11:00:00	11.8	1006.0	55.0	1.0	0.0	0.0	8474.0	3228.0	7097.0	753.0	3885.0	2906.0	24133.0	60.12
2015-01-01 12:00:00	11.8	1006.0	55.0	1.0	0.0	0.0	8613.0	3249.0	7099.0	749.0	4007.0	2923.0	24713.0	62.05
2015-01-01 13:00:00	11.4	1025.0	54.5	2.0	0.0	0.0	8461.0	2996.0	7097.0	749.0	3973.0	2945.0	24672.0	62.06

Se ha finalizado el proceso de Exploración de los Datos.

El conjunto de datos resultantes consta de 31.601 filas y de 13 columnas;

- 'temp'
- 'pressure'
- 'humidity'
- 'wind_speed'
- 'water_collected'
- 'clouds_all'
- 'generation fossil'
- 'generation hydro'
- 'generation nuclear'
- 'generation other'
- 'generation solar'
- 'generation wind'
- 'total load actual'
- 'price actual'

La columna de precio será a asignada como ‘target’ para el siguiente paso, el Estudio de los modelos de ‘Machine Learning’, donde la columna de precio será asigna da como ‘target’.

IMÁGENES:

ANEXO

DOC_1. Module functions_EDA.py

```
import numpy as np
import pandas as pd


#Function explores number of Nan-Null values in each Dataframe column
def number_nan_columns(df):
    print(('number null/Nan_values of columns Dataframe:\n').upper())
    for i in range(len(df.columns)):
        print(i,df.columns[i],':',df.iloc[:,i][df.iloc[:,i].isnull()].shape[0])


#Function explores percentage of Nan-Null values in each Dataframe column
def percentage_nan_columns(df):
    lenght_col = df.shape[0]
    print(('Percentage nan_values of columns Dataframe:\n').upper())
    for i in range(len(df.columns)):
        num_nan_col = df.iloc[:,i][df.iloc[:,i].isnull()].shape[0]
        print(str(i)+'.-',df.columns[i],':',round((num_nan_col/lenght_col)*100,4),'%\n')


#Function explores percentage of Zero values in each Dataframe column
def percentage_zeros_columns(df):
    ar_num_zero = np.count_nonzero(df, axis=0)
    lenght_col = df.shape[0]
    print(('Percentage zero_values of columns Dataframe:\n').upper())
    for i in range(len(df.columns)):
        print(str(i)+'.-',df.columns[i],':',
              round(((lenght_col-ar_num_zero[i])/lenght_col)*100,3),'%\n')
```

```
  #function drop outlayers_maximum and outlayers_minimum of DataFrame
#return df
def drop_outlayers_df(df,column):
   #get 1est quartile and 3er quartile
   q1 = df[column].quantile(q=0.25)
   q3 = df[column].quantile(q=0.75)
   #inter quartile range
   iqr = q3 - q1

   #get maximun
   maximum = q3 + (1.5*iqr)

   #get minimum
   minimum = q1 - (1.5*iqr)

   #get indexes row outlayers, max and min
   idx_maximum = df[df[column] > maximum].index
   idx_minimum = df[df[column] < minimum].index

   #drop rox outlayers
   df.drop(idx_maximum, axis = 0, inplace = True)
   df.drop(idx_minimum, axis = 0, inplace = True)

   return df
```